

Objetivos del tema

Conocer las características propias de HDFS

Entender la arquitectura de HDFS

Familiarizarse con los comandos más habituales de HDFS



Características y arquitectura de HDFS

Hadoop Distributed File System (HDFS)

Sistema de archivos distribuido para almacenar archivos muy grandes con patrones de acceso en streaming, pensado para clusters de ordenadores convencionales

- Sistema de archivos distribuido: almacenamiento en una red de máquinas.
 - Máquinas commodity (hardware convencional, que puede fallar).
 - Escalable (más capacidad: añadir más nodos, en lugar de nodos más grandes)
 - Incorpora mecanismos software de recuperación frente a fallo de un nodo
- Permite archivos mayores que la capacidad del disco de una máquina individual
 - Cientos de GB, varios TB, incluso PB
- Archivos con patrón de acceso write-once, read-many.
 - No es importante el tiempo de acceso a partes individuales sino que se suele utilizar el archivo completo en las aplicaciones (modo batch, no interactivo)
 - No soporta modificación de archivos existentes. Sólo lectura, escritura y borrado
- No funciona bien para:
 - Aplicaciones que requieran baja latencia para acceder a registros individuales
 - Muchos archivos pequeños (generan demasiados metadatos)
 - Archivos que se modifiquen con frecuencia



Hadoop Distributed File System (HDFS)

- Está escrito en lenguaje Java
- Se instala encima de los sistemas de ficheros nativos de máquinas Linux (ej: ext4)
 - Utiliza la API del Sistema Operativo para leer y escribir datos en los nodos.
 - No interactúa con los dispositivos físicos (discos duros)
- Su antecesor fue Google File System (GFS) en 2003
 - Ghemawat, S.; Gobioff, H.; Leung, S. T. (2003). "The Google File System". *Proceedings of the 19th ACM Symposium on Operating Systems Principles SOSP '03, 29 43.*
- Un recurso excelente sobre la arquitectura de HDFS: http://www.aosabook.org/en/hdfs.html



Bloques en HDFS

- Bloque físico (sector) de disco: cantidad de información que se puede leer o escribir en una sola operación de disco. Habitualmente 512 bytes.
- Bloque de sistema de archivos: conjunto de sectores que se pueden reservar para leer o escribir un archivo. Suele ser configurable (ej: Linux ext4 permite 1KB, 2KB ...). Habitualmente 4 KB. Debe contener un número de sectores físicos potencia de 2.
- En sistemas de archivos convencionales (ext4, NTFS, FAT32...) los archivos menores que el bloque de sistema de archivos siguen ocupando un bloque completo.
- HDFS tiene su propio tamaño de bloque, configurable (por defecto 128 MB), pero los archivos de menos de un bloque no desperdician espacio (aunque siempre usan su propio bloque de datos; nunca se comparte un bloque de HDFS entre varios archivos)
- Implicaciones del tamaño de bloque de HDFS:
 - Un archivo se parte en bloques que pueden almacenarse en máquinas diferentes. Así se puede almacenar un archivo mayor que el disco de una sola máquina
 - Cada bloque requiere metadatos (que se almacenan en el namenode) para mantenerlo localizado. Bloques pequeños: demasiados metadatos. Bloques muy grandes: limitan el paralelismo de frameworks que operan a nivel de bloque
 - Bloques de datos replicados para alta disponibilidad y máximo paralelismo: cada bloque está en *k* máquinas (*k* : factor de replicación, por defecto 3, configurable individualmente para cada fichero: hadoop dfs -setrep -w 3 / (user/hdfs/file.txt)

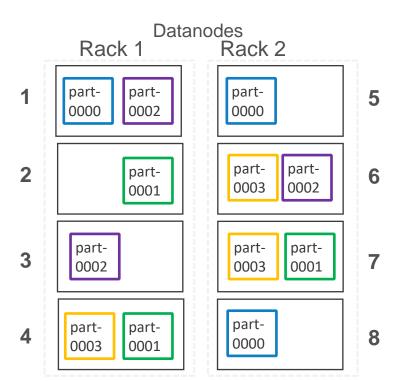
Namenode y datanodes

- Dos tipos de nodos diferentes: namenode (al menos uno) y datanodes
 - Namenode: almacena metadatos (estructura de directorios, ubicación bloques).
 - Datanodes: almacenan y sirven los bloques de datos que componen los ficheros
- Ejemplo 1: archivo flights1994.csv (500 MB) que se ha subido mediante copyFromLocal

```
[pvillacorta@meetupds1 ~]$ hdfs fsck /SparkMeetup/flights1994.csv -blocks -files
Connecting to namenode via http://meetupds1:50070/fsck?ugi=pvillacorta&blocks=1&files=1&path=%2FSparkMeetup%2Fflights1994.csv
FSCK started by pvillacorta (auth:SIMPLE) from
                                                for path /SparkMeetup/flights1994.csv at Thu Apr 18 21:43:27 CEST 2019
/SparkMeetup/flights1994.csv 501558665 bytes, 4 block(s): OK
  -1526901840376:blk 1073977386 236562 len=98905481 repl=3
  BP-2126204769-
Status: HEALTHY
                                                                  HDFS lo ha dividido automáticamente en
Total size:
            501558665 B
                                                                  4 bloques, el último más pequeño. Cada
Total dirs:
Total files: 1
                                                                  bloque está replicado 3 veces
Total symlinks:
Total blocks (validated):
                         4 (avg. block size 125389666 B)
Minimally replicated blocks:
                         4 (100.0 %)
Over-replicated blocks:
                         0 (0.0 %)
Under-replicated blocks:
                         0 (0.0 %)
Mis-replicated blocks:
                         0 (0.0 %)
Default replication factor:
Average block replication:
Corrupt blocks:
Missing replicas:
                         0 (0.0 %)
Number of data-nodes:
Number of racks:
FSCK ended at Thu Apr 18 21:43:27 CEST 2019 in 1 milliseconds
The filesystem under path '/SparkMeetup/flights1994.csv' is HEALTHY
```

Namenode y datanodes

Ejemplo 2: archivo *predic*: es el resultado de un procesamiento batch con Spark, que genera un DataFrame distribuido en 4 particiones. Al salvarlo en HDFS, Spark crea 4 archivos separados (asumimos que son pequeños y cada uno ocupa menos de 1 bloque)



Namenode

/misdatos/predic/part-0000.snappy.parquet (40 MB) nodos 1,5,8 /misdatos/predic/part-0001.snappy.parquet (40 MB) nodos 2,4,7 /misdatos/predic/part-0002.snappy.parquet (35 MB) nodos 1,3,6 /misdatos/predic/part-0003.snappy.parquet (40 MB) nodos 4,6,7

- Rack awareness: distribución de bloques optimizada para la topología concreta del cluster.
- Minimiza pérdidas si cae (falla) un rack completo de nodos y minimiza tráfico de red.
- No más de una réplica en un mismo nodo, y no más de dos réplicas en el mismo rack



Namenode y datanodes

- El namenode mantiene la estructura de directorios y los metadatos. Esta información se guarda de manera persistente como (i) imagen del namespace, y (ii) log de edición
- Los datanodes almacenan bloques de datos. Los devuelven a petición del namenode o del programa cliente que está accediendo a HDFS.
- El namenode recibe periódicamente de los datanodes un *heartbeat* (cada 3 s, dfs.heartbeat.interval) y un listado de todos los bloques presentes en cada datanode (cada 6 h, configurable en dfs.blockreport.*).
- El namenode es punto único de fallo (SPOF). Sin él, no es posible utilizar HDFS.
- Respaldo de datos del namenode (copia de seguridad preventiva frente a fallos):
 - Copia de los archivos persistentes de metadatos a otros nodos o a NFS
 - Namenode secundario (no es realmente un namenode): en otra máquina física, va fusionando los cambios del log de edición a la imagen del namespace. Suele ir con retraso respecto al original. En caso de fallo, se transfieren a él si es posible metadatos que estén en NFS, y se empieza a usar como namenode activo. Proceso manual que puede tardar hasta 30 min o más: **no es alta disponibilidad.**
- Alta disponibilidad de HDFS: par de namenodes (activo / stand-by). Log de edición compartido. Los datanodes reportan a ambos. Requiere re-implementar los clientes.
- Escalando el namenode (memoria debido a metadatos): **federación** de namenodes
 - Varios namenodes se encargan de directorios distintos del sistema de archivos (sin solapamiento, ej.: /user vs /share). El fallo de uno no afecta al resto.
 - Los datanodes sí pueden almacenar bloques de archivos de varios namespaces

Configuración de HDFS

Los ficheros de configuración se encuentran en etc/hadoop.

Filename	Format	Description	
hadoop-env.sh	Bash script	Environment variables that are used in the scripts to run Hadoop.	
core-site.xml	Hadoop configuration XML	Configuration settings for Hadoop Core, such as I/O settings that are common to HDFS and MapReduce.	
hdfs-site.xml	Hadoop configuration	Configuration settings for HDFS daemons: the namenode, the sec-	
	XML	ondary namenode, and the datanodes.	
mapred-site.xml	Hadoop configuration XML	Configuration settings for MapReduce daemons: the jobtracker, and the tasktrackers.	
masters	Plain text	A list of machines (one per line) that each run a secondary namenode.	
slaves	Plain text	A list of machines (one per line) that each run a datanode and a tasktracker.	
hadoop-metrics.properties	Java Properties	Properties for controlling how metrics are published in Hadoop ("Metrics" on page 306).	
log4j.properties	Java Properties	Properties for system logiiles, the namenode audit log, and the task log for the tasktracker child process ("Haddop Heer")	



Configuración de HDFS

File Name	Parameter Name	Parameter value	Description
core-site.xml	fs.defaultFS/fs.default.name	hdfs:// <namenode_ip>:8020</namenode_ip>	Namenode ip address or nameservice (HA config)
hdfs-site.xml	dfs.block.size, dfs.blocksize	128 MB	Block size at which files will be stored physically.
ndfs-site.xml	dfs.replication	3	Number of copies per block of a file for fault tolerance
hdfs-site.xml	dfs.namenode.http-address	0.0.0.0:50070	Namenode Web UI. By default it might use ip address of namenode.
hdfs-site.xml	dfs.datanode.http.address	0.0.0.0:50075	Datanode Web UI
ndfs-site.xml	dfs.name.dir, dfs.namenode.name.dir	<directory_location></directory_location>	Directory location for FS Image and edit logs on name node
ndfs-site.xml	dfs.data.dir, dfs.datanode.data.dir	<directory_location></directory_location>	Directory location for storing blocks on data nodes
hdfs-site.xml	fs.checkpoint.dir, dfs.namenode.checkpoint.dir	<directory_location></directory_location>	Directory location which will be used by secondary namenode for checkpoint.
hdfs-site.xml	fs.checkpoint.period, dfs.namenode.checkpoint.period	1 hour	Checkpoint (merging edit logs with current fs image to create new fs image) interval.
ndfs-site.xml	dfs.namenode.checkpoint.txns	1000000	Checkpoint (merging edit logs with current fs image to create new fs image) transactions.





Configuración de HDFS

```
Unless required by applicable law or agreed to in writing, software
  distributed under the License is distributed on an "AS IS" BASIS,
  WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
  See the License for the specific language governing permissions and
  limitations under the License. See accompanying LICENSE file.
-->
<!-- Put site-specific property overrides in this file. -->
<configuration>
cproperty>
  <name>dfs.replication</name>
   <value>1</value>
 </property>
 cproperty>
   <name>dfs.namenode.name.dir</name>
   <value>file:/usr/local/hadoop_store/hdfs/namenode</value>
 </property>
 cproperty>
   <name>dfs.datanode.data.dir</name>
   <value>file:/usr/local/hadoop store/hdfs/datanode</value>
 </property>
</configuration>
```



2 Comandos de HDFS más habituales

Listar comandos existentes

```
[root@sandbox ~]# hadoop fs
Usage: hadoop fs [generic options]
        [-appendToFile <localsrc> ... <dst>]
         [-cat [-ignoreCrc] <src> ...]
         -checksum <src> ...]
        [-chgrp [-R] GROUP PATH...]
         [-chmod [-R] <MODE[,MODE]... | OCTALMODE> PATH...]
         [-chown [-R] [OWNER][:[GROUP]] PATH...]
         [-copyFromLocal [-f] [-p] [-l] <localsrc> ... <dst>]
         [-copyToLocal [-p] [-ignoreCrc] [-crc] <src> ... <localdst>]
         [-count [-q] [-h] [-v] [-t [<storage type>]] <path> ...]
         -cp [-f] [-p | -p[topax]] <src> ... <dst>]
         -createSnapshot <snapshotDir> [<snapshotName>]]
         -deleteSnapshot <snapshotDir> <snapshotName>1
         [-df [-h] [<path> ...]]
         [-du [-s] [-h] <path> ...]
         -expungel
         [-find <path> ... <expression> ...]
         [-get [-p] [-ignoreCrc] [-crc] <src> ... <localdst>]
         [-getfacl [-R] <path>]
         [-getfattr [-R] {-n name | -d} [-e en] <path>]
        [-getmerge [-nl] <src> <localdst>]
        [-help [cmd ...]]
        [-ls [-C] [-d] [-h] [-q] [-R] [-t] [-S] [-r] [-u] [<path> ...]]
```



Mostrar archivos

```
[root@sandbox ~]# hadoop fs -ls /
Found 12 items
drwxrwxrwx
            - yarn hadoop
                                     0 2016-10-25 08:10 /app-logs

    hdfs hdfs

drwxr-xr-x
                                     0 2016-10-25 07:54 /apps
drwxr-xr-x - yarn hadoop
                                     0 2016-10-25 07:48 /ats
           - hdfs
                     hdfs
                                     0 2016-10-25 08:01 /demo
drwxr-xr-x
           hdfs
                     hdfs
                                     0 2016-10-25 07:48 /hdp
drwxr-xr-x

    mapred hdfs

drwxr-xr-x
                                     0 2016-10-25 07:48 /mapred
drwxrwxrwx

    mapred hadoop

                                     0 2016-10-25 07:48 /mr-history
drwxr-xr-x
            hdfs
                     hdfs
                                     0 2016-10-25 07:47 /ranger
            - spark hadoop
                                     0 2017-02-02 11:46 /spark-history
drwxrwxrwx
drwxrwxrwx
           - spark hadoop
                                     0 2016-10-25 08:14 /spark2-history
drwxrwxrwx
            - hdfs hdfs
                                     0 2016-10-25 08:11 /tmp
            hdfs
                     hdfs
drwxr-xr-x
                                     0 2016-10-25 08:11 /user
root@sandbox ~]#
```



Crear directorios

```
root@sandbox ~]# hadoop fs -mkdir /raul
root@sandbox ~l# hadoop fs -ls /
Found 13 items
                     hadoop
drwxrwxrwx - yarn
                                    0 2016-10-25 08:10 /app-logs
drwxr-xr-x - hdfs hdfs
                                     0 2016-10-25 07:54 /apps
                     hadoop
drwxr-xr-x - yarn
                                     0 2016-10-25 07:48 /ats
drwxr-xr-x - hdfs
                     hdfs
                                     0 2016-10-25 08:01 /demo
drwxr-xr-x - hdfs
                     hdfs
                                     0 2016-10-25 07:48 /hdp

    mapred hdfs

                                     0 2016-10-25 07:48 /mapred
drwxr-xr-x

    mapred hadoop

                                     0 2016-10-25 07:48 /mr-history
drwxrwxrwx
            - hdfs
                     hdfs
                                     0 2016-10-25 07:47 /ranger
drwxr-xr-x
                    hdfs
                                     0 2017-02-02 11:48 /raul
drwxr-xr-x - root
                                     0 2017-02-02 11:48 /spark-history
                     hadoop
drwxrwxrwx
            - spark
                                     0 2016-10-25 08:14 /spark2-history
drwxrwxrwx
            - spark
                     hadoop
drwxrwxrwx
            hdfs
                     hdfs
                                     0 2016-10-25 08:11 /tmp
drwxr-xr-x
            hdfs
                     hdfs
                                     0 2016-10-25 08:11 /user
```



Copiar desde el disco local a HDFS y viceversa

```
hadoop fs -copyFromLocal <localsrc> <dst> hadoop fs -copyToLocal <src> <localdst>
```

Inspeccionando ficheros

```
[root@sandbox raul]# hadoop fs -tail /demo/data/CDR/recharges.txt
00
6641609561|20130209|094637|3|100
6650359180|20130209|125420|3|100
6638378345|20130209|121231|3|300
6659538250|20130209|191504|3|100
6662032971|20130209|211136|3|500
8333654388|20130209|100458|3|100
6623568405|20130209|121240|3|100
```

```
[root@sandbox raul]# hadoop fs -cat /demo/data/CDR/recharges.txt | more PHONE|DATE|CHANNEL|PLAN|AMOUNT 7852121521|20130209|090721|3|100 7642140929|20130209|181648|3|100 7552204414|20130209|224815|3|100 7785846460|20130209|173731|3|100 7972930496|20130209|003527|3|100 7782957598|20130209|200016|3|100 7352795440|20130209|000429|3|100
```



Copiar, mover y borrar

```
root@sandbox raul]# hadoop fs -ls /demo/data/CDR/
Found 2 items
rwx----- 1 hdfs hdfs 710436 2016-10-25 08:01 /demo/data/CDR/cdrs.txt
rwx----- 1 hdfs hdfs 68095 2016-10-25 08:01 /demo/data/CDR/recharges.txt
root@sandbox raul]# hadoop fs -cp /demo/data/CDR/cdrs.txt /demo/data/CDR/cdrs2.txt
root@sandbox raul]# hadoop fs -ls /demo/data/CDR/
ound 3 items
rwx----- 1 hdfs hdfs 710436 2016-10-25 08:01 /demo/data/CDR/cdrs.txt
                        710436 2017-02-02 12:01 /demo/data/CDR/cdrs2.txt
rw-r--r-- 1 root hdfs
rwx----- 1 hdfs hdfs
                            68095 2016-10-25 08:01 /demo/data/CDR/recharges.txt
root@sandbox raul]# hadoop fs -rm /demo/data/CDR/cdrs2.txt
17/02/02 12:01:52 INFO fs.TrashPolicyDefault: Moved: 'hdfs://sandbox.hortonworks.com:80
/user/root/.Trash/Current/demo/data/CDR/cdrs2.txt
root@sandbox raul]# hadoop fs -ls /demo/data/CDR/
ound 2 items
rwx----- 1 hdfs hdfs
                           710436 2016-10-25 08:01 /demo/data/CDR/cdrs.txt
rwx----- 1 hdfs hdfs
                            68095 2016-10-25 08:01 /demo/data/CDR/recharges.txt
[root@sandbox raul]#
```

```
hadoop fs -cp <src> <dst>
hadoop fs -mv <src> <dst>
hadoop fs -rm [-r] <path> ...
```



Otros comandos

```
[root@sandbox raul]# hadoop fs -help |
                                       more
Usage: hadoop fs [generic options]
        [-appendToFile <localsrc> ... <dst>]
        [-cat [-ignoreCrc] <src> ...]
        -checksum <src> ...l
        -chgrp [-R] GROUP PATH...]
        -chmod [-R] <MODE[,MODE]... | OCTALMODE> PATH...]
        [-chown [-R] [OWNER][:[GROUP]] PATH...]
        -copyFromLocal [-f] [-p] [-l] <localsrc> ... <dst>]
        [-copyToLocal [-p] [-ignoreCrc] [-crc] <src> ... <localdst>]
        [-count [-q] [-h] [-v] [-t [<storage type>]] <path> ...]
        [-cp [-f] [-p | -p[topax]] <src> ... <dst>]
        -createSnapshot <snapshotDir> [<snapshotName>]]
        -deleteSnapshot <snapshotDir> <snapshotName>]
        -df [-h] [<path> ...]]
        -du [-s] [-h] <path> ...]
        -expungel
        -find <path> ... <expression> ...]
```



Otros comandos

```
chown [-R] [OWNER][:[GROUP]] PATH...:
Changes owner and group of a file. This is similar to the shell's chown command
with a few exceptions.
 -R modifies the files recursively. This is the only option currently
    supported.
 If only the owner or group is specified, then only the owner or group is
 modified. The owner and group names may only consist of digits, alphabet, and
 any of [-./@a-zA-Z0-9]. The names are case sensitive.
WARNING: Avoid using '.' to separate user name and group though Linux allows it.
 If user names have dots in them and you are using local file system, you might
 see surprising results since the shell command 'chown' is used for local files.
copyFromLocal [-f] [-p] [-l] <localsrc> ... <dst> :
Identical to the -put command.
copyToLocal [-p] [-ignoreCrc] [-crc] <src> ... <localdst> :
Identical to the -get command.
count [-q] [-h] [-v] [-t [<storage type>]] <path> ... :
Count the number of directories, files and bytes under the paths
 that match the specified file pattern. The output columns are:
DIR COUNT FILE COUNT CONTENT SIZE PATHNAME
```

Otros comandos

```
-test -[defsz] <path> :
Answer various questions about <path>, with result via exit status.
-d return 0 if <path> is a directory.
-e return 0 if <path> exists.
-f return 0 if <path> is a file.
-s return 0 if file <path> is greater
-w return 0 if file <path> exists and write permission is granted.
-r return 0 if file <path> exists and read permission is granted.
-z return 0 if file <path> is zero bytes in size, else return 1.
```



3 Formatos de archivo frecuentes en HDFS

Archivos Parquet



- Apache Parquet (2013): formato columnar, comprimido (binario). Utiliza record-shredding para almacenar tipos de datos complejos y anidados (un CSV no es capaz)
- Almacena el esquema junto a los datos. También máx/mín por columna (resúmenes)
- Los valores de cada columna se guardan físicamente juntos (almacenamiento columnar). Beneficios:
 - Compresión de datos por cada columna para ahorrar espacio
 - Se pueden aplicar técnicas de compresión diferentes, específicas según el tipo de dato que almacena cada columna
 - Las consultas con filtrados sobre columnas concretas no necesitan leer toda la fila, mejorando el rendimiento
- Preparado para añadir más esquemas de codificación que se desarrollen en el futuro
- No requiere especificar separador de columnas, ni si se incluyen o no nombres de columna (siempre se incluyen por defecto)
- Es con diferencia el formato más ampliamente utilizado para procesamiento en batch, tanto para datos de entrada como para guardar resultados, con datos estructurados.



Archivos ORC



- ORC: Optimized Row Columnar
- Similar a Parquet: binario, columnar, con compresión y con índices, además de almacenar estadísticas simples sobre los valores por grupos de filas
- Almacena el esquema junto a los datos.
- Como HDFS está pensado para accesos donde se escribe una sola vez (inmutables) y se lee muchas veces, los propios formatos Parquet y ORC no soportan modificaciones.
- Parquet y ORC optimizan las lecturas a costa de escrituras más costosas en tiempo

Archivos Avro



- Formato binario orientado a filas, con compresión. Típico para serialización
- ▶ El esquema se almacena en un fichero separado: AVRO schema file (.avsc)
- Finalidad principal: datos cuyo el esquema evoluciona



4 Practicando con Dataproc



Archivo flights-jan-apr-2018.csv en vuestro portátil



Interfaz gráfica de GCS (Browser)



Google Cloud Storage



Internet: flights_jan08.csv en github









HDFS

hdfs dfs -mkdir /datos hdfs dfs -copyFromLocal

Archivo flights_jan08.csv en el sistema de ficheros Linux de la máquina donde corre JupyterLab



Una vez que tenemos el fichero subido a GCS, simplemente podemos lanzar comandos de HDFS que también funcionan contra Google Cloud (gracias a Google) a pesar de que GCS no tiene nada que ver con HDFS:

```
hdfs dfs -ls gs://nombrebucket/data
```

- Como el fichero ya lo habíamos subido a GCS con la interfaz gráfica, ya hay poco que hacer aquí. Para practicar un poco más, vamos a manejar HDFS como tal, y para ello, vamos primero a descargar de internet un fichero pequeño a la máquina en la que tenemos abierta la terminal (es decir, la máquina donde está corriendo JupyterLab).
- Al abrir la terminal de Linux en JupyterLab, estamos situados por defecto en / . Además, es una terminal poco práctica por lo que primero vamos a abrir la terminal llamada *bash* escribiendo *bash*.
 - La terminal bash sí nos permite ir viendo comandos ejecutados antes pulsando las teclas arriba y abajo.
- Una vez estamos en bash, descargamos el fichero a la "ubicación actual" del sistema de ficheros local:

```
wget https://github.com/olbapjose/xapi-clojure/blob/master/flights_jan08.csv
```

- Esto lo descarga al sistema de ficheros local de dicha máquina. Recordemos: por defecto estábamos situados en /
- Vamos a crear en HDFS una nueva carpeta llamada *datos* que cuelga del raíz, y vamos a subir ahí nuestro fichero

```
hdfs dfs -mkdir /datos
hdfs dfs -copyFromLocal flights_jan08.csv /datos
hdfs dfs -ls /datos (comprobamos que efectivamente está ahí)
```

¿Preguntas?

