

MapReduce



YARN Yet Another Resource Negotiator

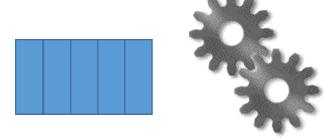


HDFS Hadoop Distributed File System

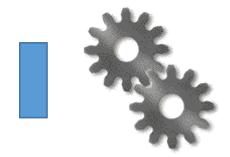


Hardware Básico

Procesamiento por lotes (Batches)

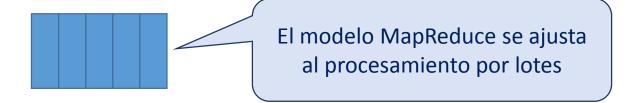


• Procesamiento en tiempo real (Streaming)





Procesamiento por lotes (Batches)



• Procesamiento en tiempo real (Streaming)



Procesamiento por lotes (Batches)



Mapper

Mapper

Mapper

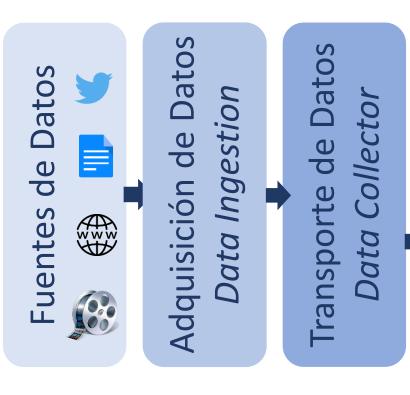
Mapper

Mapper



- Macro Batch: Más de 15 minutos.
- Micro Batch: Entre 2 y 15 minutos.
- Near Real-Time Decision Support: Entre 2 segundos y 2 minutos.
- Near Real Time Event Processing: Entre 100 milisegundos y 2 segundos.
- Real-Time: Menos de 100 milisegundos.





MapReduce



YARN Yet Another Resource Negotiator



HDFS Hadoop Distributed File System



Hardware Básico

- Recolección de información procedente de múltiples fuentes.
 - Extracción de los "datos".
 - ➤ Validación de los datos.

- Integración de los datos en el sistema de procesamiento.
 - ➤ Colocar los datos en los destinos apropiados.



Desafíos de la Adquisición de datos

- Enorme cantidad de fuentes de datos en crecimiento.
 - ➤ Diferentes tipos de datos y formatos.
 - ➤ Generación de datos a gran velocidad.
- Fuentes de datos en constante evolución.
 - ➤ Cambios en los datos generados.
 - Cambios en la semántica de los datos.
 - > Detección de los cambios en los datos.



Requisitos del sistema de Adquisición

- Gestionar nuevos tipos de datos, tecnologías y aplicaciones.
- Asegurar la corrección, consistencia y valor de los datos.
- Permitir la rápida integración de datos.
- Escalar de acuerdo con el volumen de los datos de entrada.
- Agregar datos de entrada para reducir el volumen.



Consideraciones del sistema de Adquisición

- Ancho de banda de la red (Network Bandwidth).
- Posibilidad de fallos en la red.
- Tecnologías y sistemas heterogéneos.
- Conversión de datos de distinto formato.







